



(1ACC0216)

Fundamentos de Data Science

TB2-Trabajo 2- Final

CICLO 2026-1

TEMA: CREACION DE CONOCIMIENTO APLICANDO LA METODOLOGÍA CRISP-DM

Objetivo

Desarrollar una propuesta de análisis y analítica a partir de un conjunto de datos, aplicando la metodología **CRISP-DM**, y teniendo las siguientes consideraciones:

- Crear conocimiento y valor a partir de los datos.
- Fundamentar y tomar decisiones basadas en los datos.

La metodología **CRISP-DM** permite una constante comunicación entre todos los integrantes del equipo de trabajo durante el proceso de desarrollo de un proyecto de analítica, lo cual permite la adaptación a los cambios de los requisitos, diseño y otros factores.

Competencias

Serán evaluadas las competencias:

- Pensamiento Innovador - Nivel 2
- Trabajo Multidisciplinario - Nivel 1

Según Rúbrica: **1ACC0216-TB2**

El estudiante demostrará lo aprendido sobre los Fundamentos de Data Science, aplicando de forma práctica: la teoría, técnicas y herramientas utilizadas para el análisis y analítica a lo largo del ciclo de vida de un Proyecto de Ciencia de Datos.

Descripción del Proyecto de Ciencia de Datos

Alcance

Una consultora internacional, con sede en Lima, solicita desarrollar un proyecto de Ciencia de Datos con la finalidad de conocer las tendencias de los videos de YouTube en siete importantes países.

El proyecto responde a la necesidad de su cliente, una importante empresa de marketing digital, que desea obtener respuestas a varios requerimientos de información.

Requerimientos

A continuación, se detalla una lista de preguntas que el proyecto al finalizar deberá dar respuesta.

■ Por Categoría de Videos

1. ¿Qué categorías de videos son las de mayor tendencia?
2. ¿Qué categorías de videos son los que más gustan? ¿Y las que menos gustan?
3. ¿Qué categorías de videos tienen la mejor proporción (ratio) de “Me gusta” / “No me gusta”?
4. ¿Qué categorías de videos tienen la mejor proporción (ratio) de “Vistas” / “Comentarios”?

■ Por el tiempo transcurrido

5. ¿Cómo ha cambiado el volumen de los videos en tendencia a lo largo del tiempo?

■ Por Canales de YouTube

6. ¿Qué Canales de YouTube son tendencia más frecuentemente? ¿Y cuáles con menos frecuencia?

■ Por la geografía del país

7. ¿En qué Estados se presenta el mayor número de “Vistas”, “Me gusta” y “No me gusta”?

Adicionalmente, al cliente le gustaría conocer si:

8. ¿Los videos en tendencia son los que mayor cantidad de comentarios positivos reciben?
9. ¿Es factible predecir el número de “Vistas” o “Me gusta” o “No me gusta”?

Equipo de Trabajo

Se han conformado cuatro equipos de proyecto, el primero conformado por 3 grupos (sección 3227), el segundo 5 grupos (sección 16310), el tercero por 5 grupos (sección 16685) y el cuarto por 5 grupos (sección NRC), cada uno de ellos compuesto por los mejores estudiantes de la carrera de Ciencias de la Computación de la Universidad Peruana de Ciencias Aplicadas (UPC).

Cada grupo será responsable de responder a los requerimientos según el conjunto de datos correspondiente al país que le sea asignado, utilizando el conocimiento y las herramientas aprendidas durante la asignatura de Fundamento de Data Science, y respetando la estructura del documento entregable, así como el cumplimiento de su entrega y publicación en la fecha establecida.

Conjunto de Datos



El conjunto de datos motivo de análisis se denomina **Tendencias de las estadísticas de videos de YouTube** (Trending YouTube Video Statistics). Este conjunto de datos es un registro diario de los videos de YouTube de mayor tendencia, cuyo contenido incluye varios meses sobre datos

de tendencias diarias de videos en los siguientes países:

- EE. UU. (US)
- Gran Bretaña (GB)
- Alemania (DE)
- Canadá (CA)
- Francia (FR)
- Rusia (RU)
- México (MX)
- Corea del Sur (KR)
- Japón (JP)
- India (IN)

Los datos de cada país se encuentran en archivos individuales en formato CSV y la descripción de sus categorías en un archivo de tipo JSON.

Este conjunto de datos, en su versión original se obtiene desde el sitio web [Kaggle](https://www.kaggle.com), sin embargo, para este proyecto, ha sido modificado incorporándole cuatro nuevas columnas:

- **state:** nombre del Estado perteneciente al país (incorporado de forma aleatoria).
- **lat:** latitud geográfica de ubicación del Estado.

- **lon:** longitud geográfica de ubicación del Estado.
- **geometry:** (opcional) registra las coordenadas de las geometrías donde se ubica el Estado dentro del planeta. Es de utilidad si se decide utilizar la librería GeoPandas para la elaboración de mapas.

A cada grupo perteneciente a uno de los dos equipos de proyecto se le ha asignado un conjunto de datos por país de forma aleatoria, siendo este el resultado:

Equipo de Trabajo #1 (Sección 3227)

Nro. Grupo	País asignado	Archivos a descargar
1	Canadá (CA)	CAvideos.csv CA_category_id.json
2	Alemania (DE)	DEvideos.csv DE_category_id.json
3	Francia (FR)	FRvideos.csv FR_category_id.json

Equipo de Trabajo #2 (Sección 16310)

Nro. Grupo	País asignado	Archivos a descargar
1	Gran Bretaña (GB)	GBvideos.csv GB_category_id
2	India (IN)	INvideos.csv IN_category_id.json
3	México (MX)	MXvideos.csv MX_category_id.json
4	EE. UU. (US)	USvideos.csv US_category_id.json
5	Canadá (CA)	CAvideos.csv CA_category_id.json

Equipo de Trabajo #3 (Sección 16685)

Nro. Grupo	País asignado	Archivos a descargar
1	Alemania (DE)	DEvideos.csv DE_category_id.json
2	Francia (FR)	FRvideos.csv FR_category_id.json
3	Gran Bretaña (GB)	GBvideos.csv GB_category_id
4	India (IN)	INvideos.csv IN_category_id.json
5	México (MX)	MXvideos.csv MX_category_id.json

Equipo de Trabajo #4 (Sección NRC)

Nro. Grupo	País asignado	Archivos a descargar
1	Canadá (CA)	CAvideos.csv CA_category_id.json
2	Alemania (DE)	DEvideos.csv DE_category_id.json
3	México (MX)	MXvideos.csv MX_category_id.json
4	EE. UU. (US)	USvideos.csv US_category_id.json

El conjunto de datos modificado se puede descargar desde [AQUÍ](#).

Documento Entregable:

Cada grupo de estudiantes entregará un único documento de tipo PDF, desarrollando las siguientes secciones:

I. INTRODUCCIÓN

Explicar por qué se realizará el proyecto de Ciencia de Datos, describiendo el objetivo y el alcance del problema, así como el **conocimiento** y los insights que se buscan extraer a partir del análisis y modelado de los datos.

II. INTEGRANTES DEL GRUPO Y ROLES

Describir como fueron asignados los roles a cada integrante del grupo, así como la relación de las tareas asignadas a cada uno, especificado en qué fase/etapa del proyecto se deben ejecutar durante la vigencia del proyecto.

Los roles que participan para el desarrollo del proyecto son los siguientes:

- Business Project Sponsor
- Data Science
- Data Engineer
- Data Analyst

III. METODOLOGÍA CRISP-DM

1. COMPRENSIÓN DEL NEGOCIO

- Consiste en la comprensión y descripción de los objetivos y requisitos del proyecto.

Objetivos del proyecto

- Escriba en forma precisa el objetivo del análisis o preguntas a resolver, así como el conocimiento que se pretende estimar o predecir.

Objetivos de Data Science

- Representar los objetivos del negocio en términos de las metas del proyecto de minería de datos, identificando las variables independientes y la variable dependiente (a predecir) que el modelo debiera considerar.

Cada grupo deberá definir explícitamente una variable dependiente principal que quiera modelar. Se recomienda elegir una entre:

- Número de vistas (views)
- Número de 'Me gusta' (likes)
- Número de 'No me gusta' (dislikes)
- Número de comentarios (comment_count)

Indicar:

- Variable dependiente: nombre de columna y breve explicación.
- Variables independientes principales: al menos 4, incluyendo alguna derivada (ej. ratio likes/dislikes, días desde publicación, categoría, país/estado)."

2. COMPRENSIÓN DE LOS DATOS

- Descripción de la estructura de los datos.

Recolectar los datos iniciales

- Identificar que datos se disponen y donde se localizan.

Descripción de los datos

- Este proceso implica la identificación y la descripción de cada campo/columna

Exploración de los datos

- Encontrar una estructura general para los datos.
- Este análisis está compuesto por las tareas de carga, inspección y visualización de los datos.

CARGAR LOS DATOS

INSPECCIONAR LOS DATOS

- Los equipos deberán explorar los datos, verificando, por ejemplo: estructura, tipo, valores de los datos, nombre de columnas, creación de tablas de frecuencia.

VISUALIZAR LOS DATOS

Toda visualización deberá tener un título, una leyenda y de ser necesario, una tabla de datos que complemente su entendimiento.

Verificar la calidad de los datos

- Se determina la consistencia de los valores individuales de los campos, verificar la cantidad y distribución de los valores nulos, y encontrar valores fuera de rango, los cuales logran constituirse en ruido para el proceso. La idea una vez llegados a este punto es poder garantizar la completitud y corrección de los datos.

3. PREPARACIÓN DE LOS DATOS

- En esta fase se ejecuta la preparación de los datos para adaptarlos a las técnicas/algoritmos de Data Mining que serán seleccionadas. Asimismo, responder los requerimientos solicitados.

Limpiar los datos

- Esta tarea es una de las que más tiempo y esfuerzo consume debido a la diversidad de técnicas que pueden aplicarse para optimizar la calidad de los datos.

PRE-PROCESAR LOS DATOS

- Verificar datos faltantes: analizar la aplicación de alguna técnica para su tratamiento.
- Explicar que técnica fue utilizada para eliminar o completar los datos faltantes.
- Identificación de los datos atípicos u outliers (si los hubiera).
- Aplicar y explicar que técnica(s) fueron utilizada(s) para transformar los datos atípicos (si los hubiera).

Construir nuevos datos

- Esta tarea incluye las operaciones de preparación de los datos.
- Considerar crear nuevas columnas de datos de ser necesario a partir de las ya existentes.
- Realizar transformación (reducción de dimensionalidad o compresión de datos) si lo estiman necesario.

REQUERIMIENTOS

- Producto del análisis de los datos desarrollado hasta este punto, con los datos limpios (y a partir del nuevo conjunto de datos limpio generado), se deberá dar respuesta a los requerimientos solicitados.
- Tener en cuenta que cada respuesta deberá estar acompañada de una visualización. Como ejemplo, a continuación, una visualización para el requerimiento número siete:



4.MODELADO Y EVALUACIÓN DE RESULTADOS

En esta fase se busca establecer las técnicas de modelado más apropiadas para el proyecto de Data Mining específico de acuerdo con los objetivos planteados.

Escoger la técnica de modelado

- Esta tarea consiste en la selección de la técnica de Data Mining más apropiada al tipo de problema que se quiere resolver. Por ejemplo, si el problema es de predicción: análisis de regresión lineal/regresión logística.

Generar el plan de prueba

- Una vez determinado el modelo, se construye y adicionalmente se debe generar un procedimiento destinado a probar la calidad y validez de este. Por ejemplo, en una tarea supervisada de Data Mining como la clasificación, es común usar la razón de error como medida de la calidad. Entonces, típicamente se separan los datos en dos conjuntos, uno de entrenamiento y otro de prueba.

Construir el modelo

- A continuación, se ejecuta la técnica seleccionada sobre los datos previamente preparados para generar uno o más modelos.

Evaluar el modelo

- Aplicar métricas que permitan determinar el rendimiento del modelo en cuanto a la precisión y/o exactitud de los resultados obtenidos.

4. CONCLUSIONES

4.1 Conclusiones de negocio

3–5 bullets responder explícitamente a las preguntas del cliente.

4.2 Conclusiones técnicas

Qué funcionó bien o mal en el procesamiento, modelado, calidad de datos.

4.3 Limitaciones

Ej.: posible sesgo del dataset, datos simulados de estados, variables no disponibles.

4.4 Trabajo futuro

Qué harían si tuvieran más tiempo/datos.

5. ARCHIVAR Y COMUNICAR/PUBLICAR:

Se deberá contemplar [un repositorio en Github.com](#) llamado FDS-2026-1-3227, FDS-2026-1-16310, FDS-2026-1-16685, FDS-2026-1-NRC según la sección, conteniendo dos carpetas:

- **data:** deberá contener el conjunto de datos inicial y el final resultante (limpio o preparado para análisis).
- **code:** deberá contener los notebooks desarrollados en lenguaje de programación Python, que contemple la codificación de todas las tareas necesarias sobre el conjunto de datos, de acuerdo con las etapas anteriormente descritas que conforman la metodología CRISP-DM.

El archivo. Readme, dentro de GitHub, deberá contemplar:

- Objetivo del proyecto.
- Nombre de los alumnos participantes.
- Breve descripción del conjunto de datos (se puede adjuntar el archivo PDF).
- Conclusiones.
- Licencia de uso.

Puede tomar como guía estos ejemplos de publicaciones de trabajos en GitHub:

<https://github.com/fernandoabcampos/titanic-data-cleaning-and-validation>

<https://github.com/navarroyepes/TCVDPAC2>

En el documento entregable, se deberá incluir el enlace a la cuenta de GitHub.com desde donde se accede a la publicación del proyecto.

6. BIBLIOGRAFIA

Consideraciones adicionales

- El documento lo que debe incluir es un detalle paso a paso sobre la aplicación de la metodología CRISP-DM (Hasta el punto 4 Modelado)
- Se evaluará el orden dentro de la organización del documento, así como la correcta redacción y gramática.
- Se valorarán las respuestas a preguntas que no hayan sido propuestas en la presente evaluación.
- La exposición de las conclusiones del presente trabajo final (archivo pptx/genially, etc.) será en fecha y hora programada durante la **semana 15**.

Nomenclatura de Archivos

upc-2026-01-sección-nrogrupo-tf.pdf

upc-2026-01-sección-nrogrupo-tf(.pptx,genially,canva,etc.)

upc-2026-01-sección-nrogrupo-tf.ipynb

Sólo se debe entregar **un archivo pdf** , **un archivo de presentación** y **un archivo Python** con el código utilizado.